

Project Overhaul und Refactoring der digitalen Edition der ‘Urfehdebücher der Stadt Basel’ mithilfe von GPT-4 und LLM

Pollin, Christopher

christopher.pollin@uni-graz.at
Institut Zentrum für Informationsmodellierung,
Universität Graz, Österreich
ORCID: 0000-0002-4879-129X

Scholger, Martina

martina.scholger@uni-graz.at
Institut Zentrum für Informationsmodellierung,
Universität Graz, Österreich
ORCID: 0000-0003-1438-3236

Steiner, Elisabeth

elisabeth.steiner@uni-graz.at
Institut Zentrum für Informationsmodellierung,
Universität Graz, Österreich
ORCID: 0000-0001-9116-0402

Lang, Sarah

sarah.lang@uni-graz.at
Institut Zentrum für Informationsmodellierung,
Universität Graz, Österreich

Galka, Selina

selina.galka@uni-graz.at
Institut Zentrum für Informationsmodellierung,
Universität Graz, Österreich
ORCID: 0000-0003-4476-315X

Schiller-Stoff, Sebastian

sebastian.stoff@uni-graz.at
Institut Zentrum für Informationsmodellierung,
Universität Graz, Österreich
ORCID: 0000-0001-6941-113X

Einleitung und Begriffsdefinitionen

Ziel dieses Beitrags ist die Erprobung des Einsatzes von Large Language Models (LLMs) wie GPT-4 (*OpenAI 2023*) für das Overhauling und Refactoring von Projekten in den Digital Humanities am Beispiel der digitalen

Edition “Urfehdebücher der Stadt Basel” (UFBAS; <https://gams.uni-graz.at/ufbas>). Im Rahmen dieses Refactoring- und Overhauling-Prozesses, der sich auf die Überarbeitung von Daten, Datenmodell, Website und Code bezieht, werden LLMs für die verschiedenen Arbeitsschritte eingesetzt, getestet und evaluiert. Ziel ist es, zu evaluieren, inwieweit LLMs in der Lage sind, Arbeitsschritte KI-assistiert abzuarbeiten, und ob ihre Outputs den Standards der Digital Humanities entsprechen und in der Praxis anwendbar sind.

LLMs sind fortgeschrittene KI-Systeme, die auf die Erzeugung und das Verarbeiten menschlicher Sprache spezialisiert sind. Sie “lernen” aus großen Textmengen und sind in der Lage, kontextbezogene, qualitativ hochwertige Texte zu generieren. Ein prominentes Beispiel ist GPT-4 (Generative Pre-training Transformer 4), das aufgrund seiner Vielseitigkeit und Leistungsfähigkeit in verschiedenen Bereichen eingesetzt werden kann, darunter Datenmodellierung, -transformation, -visualisierung (*Chen et al. 2023*) und -programmierung (*Poldrack, Lu, und Beguš 2023; Tian et al. 2023*). Insbesondere in Kombination mit dem ChatGPT Plugin Code Interpreter erweist sich GPT-4 als eines der leistungsfähigsten Werkzeuge in diesem Bereich (*AI Explained 2023a; AI Explained 2023b*). Die Anwendungsmöglichkeiten von LLMs erstrecken sich auch auf Bereiche wie Datengenerierung, Prototyping und Ontology Engineering bzw. Datenmodellierung, wie (*Pollin 2023*) zeigen konnte. Das größte Potenzial kann entfaltet werden, wenn sehr gute Kenntnisse im Prompt Engineering mit hohem Domänenwissen kombiniert werden und das “Human in the Loop”-Paradigma verfolgt wird. Mit anderen Worten: Es findet eine kontinuierliche Bewertung des Outputs eines LLM durch Expert*innen aus der Domäne statt und die KI wird assistierend in den Arbeitsprozess integriert. Die Custom GPTs von OpenAI (<https://openai.com/blog/introducing-gpts>) ermöglichen es, solche Prozesse mit einer eigenen Wissensbasis und System Prompts (Instruction) zu optimieren.

In der Softwareentwicklung bezeichnet der Begriff **Overhaul** eine tiefgreifende Umstrukturierung von Systemen mit dem Ziel, deren Leistungsfähigkeit zu verbessern oder sie an die neuesten Standards und Anforderungen anzupassen. Dies beinhaltet häufig erhebliche Änderungen der Architektur, der Funktionalität und des Designs von Websites und Webschnittstellen. Ein Redesign wird dann notwendig, wenn ein Projekt so veraltet ist, dass es nicht mehr den aktuellen Anforderungen an Wartung, Sicherheit und Benutzerfreundlichkeit entspricht. Ein solcher Prozess kann im Rahmen eines Refactorings stattfinden. **Refactoring** ist ein Prozess in der Softwareentwicklung, bei dem der Quellcode überarbeitet wird, um seine Struktur zu verbessern, ohne das äußere Verhalten der Software zu verändern. Ziel ist es, den Code übersichtlicher, wartbarer und flexibler zu machen. Häufig wird ein Refactoring im Rahmen einer Neugestaltung einer Webpräsenz durchgeführt, insbesondere um die technischen Aspekte des Systems zu optimieren.

Ziel dieser Studie ist es, das Unterstützungspotential von LLMs wie GPT-4 im Bereich des Code Overhauling und Refactoring zu untersuchen. Dabei soll nicht nur der Pro-

zess der Codeoptimierung beleuchtet werden, sondern auch die Möglichkeiten und Grenzen von LLMs in diesem Kontext aufgezeigt werden. Es soll analysiert werden, inwieweit solche Modelle und Methoden als Lösungen für aktuelle Herausforderungen in den Digital Humanities dienen können.

Fallstudie UFBAS

Das Projekt UFBAS (*Burghartz, Calvi und Vogeler 2017; Pollin und Vogeler 2017*) unter der Leitung von Susanna Burghartz umfasst die digitale Edition des Urfehdebuchs der Stadt Basel für die Jahre 1563 bis 1569, die trotz ihres inhaltlichen Werts in ihrer technischen Umsetzung Verbesserungspotential aufweist und dem heutigen Stand der Technik angepasst werden muss. UFBAS wurde 2017 im Rahmen eines einjährigen Projekts am Zentrum für Informationsmodellierung (ZIM) durch einen studentischen Mitarbeiter mit begrenzten personellen Ressourcen umgesetzt und im **Geisteswissenschaftlichen Asset Management System** (GAMS; *Stigler und Steiner 2018*) veröffentlicht.

Die verschiedenen Revisionsschritte sollen mit Hilfe von GPT-4, den vorhandenen Plugins und insbesondere dem Plugin Code Interpreter, sowie einem projektspezifischen Custom GPT unterstützt werden. Das Vorgehen orientiert sich dabei an den Experimenten, die in der Workshopreihe “Angewandte Generative KI in den (digitalen) Geisteswissenschaften” (<https://chpollin.github.io/GM-DH> ; *Pollin 2023*) erprobt wurden. Die Ergebnisse der GPT-4 assistierten Prozesse werden auf <https://github.com/chpollin/Overhaul-UFBAS> veröffentlicht.

Angestrebte Verbesserungen

Die in diesem Projekt geplanten Verbesserungen umfassen eine Vielzahl von Aspekten: Die Aktualisierung und Erweiterung der Datenbasis und der Metadaten, die Neugestaltung des Datenmodells durch eine Ontologie, die auf der Top-Level-Ontologie CIDOC-CRM basiert, und die Entwicklung eines TEI XML ODD. Auch das Refactoring des JavaScript- und XSLT-Codes, der für die RDF-Generierung und die Webentwicklung verwendet wird, ist ebenfalls geplant. Ein weiterer Fokus liegt auf der Verbesserung der HTML5-Validierung, der Barrierefreiheit und der Responsivität der Webpräsenz. Darüber hinaus ist die Erstellung prototypischer Datenvisualisierungen geplant, wobei Design und Implementierung durch das ChatGPT-Plugin „Code Interpreter“ wesentlich unterstützt werden können. Diese Auflistung umfasst einige der geplanten Arbeitsschritte, erhebt aber keinen Anspruch auf Vollständigkeit.

TEI XML

Die TEI XML Version vom 31.1.2017 (<https://gams.uni-graz.at/o:ufbas.1563>) wird grundlegend überarbeitet. Einige dieser Änderungen können als trivial angesehen werden und erfordern kein LLM. Der eigentliche Nutzen liegt jedoch in der unterstützten bzw. automatisierten Generierung eines Scripts durch GPT-4, das basierend auf dem Projektkontext, den Problemen und Beispielen im Prompt bzw. in der Conversation bereitgestellt wird. Dies minimiert manuelle Eingriffe und verbessert die Effizienz und Genauigkeit des gesamten Prozesses. Dies beinhaltet die folgenden beispielhaften Aufgaben:

- Anpassung der @ana-Referenzen zur semantischen Anreicherung des edierten Textes: @ana="#uf_Eintrag" zu @ana="uf:entry".
- Überarbeitung des teiHeaders in Anlehnung an das tei-Header Template, das in den letzten Jahren am ZIM als Standard festgelegt wurde.
- Vereinheitlichung im Rahmen der am ZIM erarbeiteten Coding Conventions, z.B. bei der Vergabe von @xml:id.
- Normalisierungen und Verlinkungen von Entitäten, wie beispielsweise Taten oder Strafen.
- Erstellung eines ODD Files auf Basis des TEI XML.

Die GPT-Assistenz umfasst die Analyse und die Fehlersuche im TEI XML, sowie das darauf aufbauende Programmieren der Datentransformation mittels XSLT oder Python.

Kategorien & SKOS

Die im TEI XML referenzierten Kategorien sind derzeit in einem eigenständigen TEI XML Dokument (<https://gams.uni-graz.at/o:ufbas.kategorien>) abgebildet. Dieses Dokument wird nach SKOS überführt und die Referenzierung der Kategorien im TEI XML auf das SKOS angepasst.

Die Transformation von TEI XML nach SKOS erfolgt mit dem GPT-4 Code Interpreter. Dabei werden die Ein- und Ausgabedaten mittels “Few-Shot Prompting” übergeben und mit diesem “*In-Context-Learning*” ein Python-Skript für die Transformation generiert.

Ontologie

Im Rahmen von UFBAS wurde kein RDFS- oder OWL-File zur formalen Beschreibung des Datenmodells für RDF-Daten realisiert. Im Overhaul wird dafür eine domänenspezifische Ontologie entwickelt, die die assertive Schicht (*Vogeler 2019*) eines Eintrags in einem Urfehdebuch beschreibt. Diese Ontologie beschreibt Tat, Täter und Strafe sowie weitere Phänomene, die in den RDF-Daten repräsentiert werden. Um das Alignment zu gewährleisten, ist eine CIDOC-CRM Ableitung der domänenspezifischen Ontologie enthalten.

GPT-4 wird dafür im Prozess des Ontology Engineerings eingesetzt.

RDF

Beim Ingest-Prozess in GAMS wird RDF aus TEI XML mithilfe von XSLT extrahiert. Dieses RDF (<https://gams.uni-graz.at/o:ufbas.1563/RDF>) wird an die domänenspezifische Ontologie angepasst, ebenso werden weitere Verbesserungen am RDF XML vorgenommen. Es wird getestet, welche weiteren Normalisierungen und semantischen Anreicherungen der Daten mit Wikidata möglich sind, um die FAIRness (Wilkinson et al. 2016) der Daten signifikant zu verbessern. Beispielsweise Anpassungen umfassen:

- Ergänzungen fehlender `rdf:type`.
- Vereinheitlichung von Klassen und Properties nach der Ontologie: `uf:Beruf` zu `uf:Occupation`
- Vereinheitlichung und Integration zwischenzeitlich entwickelter GAMS-spezifischer Ontologien: `g2o:inhalt` zu `gams:textualContent`.
- Metadaten zum RDF Datensatz mittels VoID Vocabulary (<https://www.w3.org/TR/void/>).
- Verwendung anderer bestehender Vokabulare wie `schema.org`, wo möglich.

GPT-4 wird im Refactoring der Transformation nach RDF eingesetzt.

Webentwicklung

Ein wichtiger Aspekt unserer Verbesserungspläne ist die Überarbeitung der Webrepräsentation. Dies umfasst nicht nur die Sicherstellung von Responsivität, Accessibility und HTML5-Validität, sondern auch das Upgrade auf Bootstrap 5 und andere JavaScript-Bibliotheken, sowie die Überarbeitung des Designs. Dabei werden auch die Such- und Explorations-Funktionalitäten der Website überarbeitet und ggf. erweitert. Insgesamt wird dadurch die FAIRness der Daten verbessert.

GPT-4 wird für die Problemanalyse, das Refactoring und die Neuentwicklungen eingesetzt.

Datenvisualisierung

Schließlich werden die Visualisierungen vollständig überarbeitet. In der UFBAS-Version vom 31.1.2017 wurde eine Netzwerkvisualisierung implementiert, die ein Suchergebnis nach einer Kategorie darstellt. Dabei wurden Täter:innen, ihre Berufe, verknüpfte Orte, Tat und Strafe in einem Graphen abgebildet. Die Aussagekraft dieser Visualisierung sowie die Handhabung sind nicht ideal, da sie eher als Experiment gegen Ende des Projekts umgesetzt wurden (<https://tinyurl.com/4nejhksf>).

GPT-4 wird während des gesamten Prozesses von der Konzeption über das Prototyping bis hin zur Implementierung eingesetzt.

Fazit

Die Integration von KI, insbesondere von GPT-4, hat das Potenzial, nicht nur das UFBAS-Projekt auf eine neue Ebene zu heben, sondern auch wertvolle Erkenntnisse und Erfahrungen zu liefern, die zur Weiterentwicklung der Anwendung von KI in den digitalen Geisteswissenschaften beitragen können.

Ziel ist es, das Potenzial neuer Technologien wie LLM und generativer KI für die Überarbeitung, Optimierung, Ergänzung und Neugestaltung bestehender digitaler Editionsprojekte auszuloten. Die gewonnenen Erkenntnisse können auch für die Konzeption neuer Projekte genutzt werden. Die Vorgehensweise und der Aufwand werden daher ausführlich dokumentiert und erläutert, was gerade bei so schnelllebigem Technologien unerlässlich ist. Im Zentrum des Überarbeitungsprozesses steht das Custom GPT “ufbasGPT” (<https://chat.openai.com/g/g-p8ZMcZK5r-ufbasgpt>), das als Überarbeitungsassistent fungiert. Dies geschieht mittels Prompting und einer Wissensbasis aller notwendigen Projektdaten. Für die Reproduzierbarkeit von Forschung, auch im Sinne von Nachnutzbarkeit und Open Science, stellt diese Technologie eine neue Herausforderung dar. Die Dokumentation des GPT-4 Overhalls wird in einem GitHub Repository veröffentlicht (<https://github.com/chpollin/Overhaul-UFBAS>). Die Ergebnisse des Overhalls werden auf einem nicht veröffentlichten Entwicklungsserver laufend angepasst und bis zur DHd2024 als neue Version in GAMS veröffentlicht.

Bibliographie

AI Explained. 2023. 12 New Code Interpreter Uses (Image to 3D, Book Scans, Multiple Datasets, Error Analysis ...). https://www.youtube.com/watch?v=_njf22xx8BQ .

AI Explained. 2023. GPT 4 Got Upgraded - Code Interpreter (Ft. Image Editing, MP4s, 3D Plots, Data Analytics and More!). https://www.youtube.com/watch?v=O8GUH0_htRM .

Andrae, Magdalena, Susanne Blumesberger, Sonja Edler, Julia Ernst, Sarah Fiedler, Doris Haslinger, Gerhard Neustätter und Denise Trieb. 2020. “Barrierefreiheit für Repositorien. Ein Überblick über technische und rechtliche Voraussetzungen”, Mitteilungen der Vereinigung Österreichischer Bibliothekarinnen und Bibliothekare, 73(2), S. 259–277. <https://doi.org/10.31263/voebm.v73i2.3640> .

Burghartz, Susanna, Sonia Calvi und Georg Vogeler. 2017. “Urfehdebücher Der Stadt Basel – Digitale Edition”, digital edition, Urfehdebücher der Stadt Basel – digitale Edition. <http://gams.uni-graz.at/context:ufbas> .

Chen, Zhutian, Chenyang Zhang, Qianwen Wang, Jakob Troidl, Simon Warchol, Johanna Beyer, Nils Gehlenborg und Hanspeter Pfister. 2023. ‘Beyond

Generating Code: Evaluating GPT on a Data Visualization Course'. <https://doi.org/10.48550/arXiv.2306.02914> .

OpenAI. 2023. 'GPT-4 Technical Report'. arXiv <https://doi.org/10.48550/ARXIV.2303.08774> .

Poldrack, Russell A., Thomas Lu und Gašper Beguš, 'AI-Assisted Coding: Experiments with GPT-4' (arXiv, 25 April 2023). <https://doi.org/10.48550/arXiv.2304.13187> .

Pollin, Christopher. 2023: Workshopreihe "Angewandte Generative KI in den (digitalen) Geisteswissenschaften" (v1.0.0). Zenodo. <https://doi.org/10.5281/zenodo.10065626> .

Pollin, Christopher und Georg Vogeler. 2017: Semantically Enriched Historical Data. Drawing on the Example of the Digital Edition of the "Urfehdebucher der Stadt Basel". WHiSe.

Stigler, Johannes und Elisabeth Steiner. 2018. 'GAMS–Eine Infrastruktur Zur Langzeitarchivierung Und Publikation Geisteswissenschaftlicher Forschungsdaten', Mitteilungen Der Vereinigung Österreichischer Bibliothekarinnen Und Bibliothekare 71, no. 1 (2018): 207–16.

Tian, Haoye, Weiqi Lu, Tsz On Li, Xunzhu Tang, Shing-Chi Cheung, Jacques Klein, Tegawendé F. Bissyandé. 2023. 'Is ChatGPT the Ultimate Programming Assistant -- How Far Is It?'. <https://doi.org/10.48550/arXiv.2304.11938> .

Vogeler, Georg. 2019. 'The "Assertive Edition"', International Journal of Digital Humanities 1, no. 2 (1 July 2019): 309–22. <https://doi.org/10.1007/s42803-019-00025-5> .

Wilkinson, Mark D. et al. 2016: The FAIR Guiding Principles for scientific data management and stewardship. Sci Data 3, 160018. <https://doi.org/10.1038/sdata.2016.18> .